



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

Actor-Critic el aprendizaje en entornos dinámicos

Actor-Critic learning in dynamic environments.

Metodología de la Investigación en
Computación.

AUTOR:

Miguel Angel Veintimilla Esparza

TUTOR:

Prof. Luis Chamba-Eras

Loja, Ecuador

2026

Declaración de uso de IA Generativa

Yo, **Miguel Angel Veintimilla Esparza**, en calidad de autor, declaro de manera transparente y responsable el uso de herramientas de Inteligencia Artificial Generativa (IAG) durante el desarrollo del presente trabajo, en conformidad con los principios de integridad académica, ética investigativa y buenas prácticas en el uso de tecnologías emergentes.

1. Alcance del uso de IA generativa

El uso de herramientas de IAG se ha limitado a funciones de apoyo, sin sustituir el juicio crítico ni la autoría intelectual del autor. En particular, se han utilizado para:

- Mejora de redacción y estilo académico.
- Generación de ideas preliminares.
- Apoyo en la estructuración del documento.
- Asistencia en traducción técnica.

2. Clasificación del uso según GAIDeT

De acuerdo con la taxonomía GAIDeT, el uso de IA generativa en este trabajo se clasifica en:

- **Nivel 1 – Asistencia Lingüística:** Corrección gramatical y mejora de claridad.
- **Nivel 2 – Apoyo en Ideación:** Generación de ideas y esquemas conceptuales.
- **Nivel 3 – Asistencia Técnica:** Apoyo en generación de código y explicaciones técnicas.

No se ha utilizado IA generativa para la generación autónoma de resultados ni para sustituir el análisis crítico del autor.

3. Validación y responsabilidad

Todo contenido asistido por IA ha sido revisado, validado y adaptado por el autor, quien asume la responsabilidad total sobre la calidad, veracidad y originalidad del trabajo.

4. Herramientas utilizadas

Se emplearon modelos de lenguaje (LLMs) y herramientas de asistencia técnica para redacción, estructuración y apoyo conceptual.

5. Consideraciones éticas

El uso de IA se realizó respetando principios de honestidad académica, normativas institucionales de la Universidad Nacional de Loja y buenas prácticas internacionales.

6. Declaración final

Declaro que el uso de IA generativa ha sido ético, transparente y complementario, sin comprometer la autoría ni la integridad académica del presente trabajo.

Loja, Ecuador, 06/05/2026

Richard Vicente Cajas Riofrío
Autor

Índice General

Declaración de uso de IA Generativa	1
1 Título	4
2 Objetivos	5
2.1 Objetivo general 1	5
2.1.1 Objetivos específicos	5
2.2 Objetivo general 2	5
2.2.1 Objetivos específicos	5
2.3 Objetivo general 3	6
2.3.1 Objetivos específicos	6
2.4 Objetivo general 4	6
2.4.1 Objetivos específicos	6
3 Metodología	7
3.1 Procedimiento	7

1. Título

Actor-Critic el aprendizaje en entornos dinámicos

2. Objetivos

2.1. Objetivo general 1

Desarrollar mecanismos que garanticen un entrenamiento estable y convergente de agentes Actor-Critic frente a la variabilidad y el ruido intrínseco de los entornos dinámicos.

2.1.1. Objetivos específicos

- Implementar métodos de entrenamiento en paralelo y actualizaciones asíncronas para romper la fuerte correlación temporal entre estados sucesivos y reducir la varianza. [1].
- Integrar el marco de máxima entropía en la política del Actor para fomentar una exploración eficiente y evitar que el agente converja prematuramente en óptimos locales. [2].
- Aplicar funciones de activación como Leaky ReLU en arquitecturas ligeras para prevenir el problema de "neuronas muertas" mantener el flujo de gradientes durante el aprendizaje. [3].

2.2. Objetivo general 2

Mejorar la velocidad de aprendizaje de los modelos Actor-Critic mediante la estructuración de tareas complejas en componentes manejables y especializados.

2.2.1. Objetivos específicos

- Diseñar Redes de Estrategia Bayesianas (BSN) para descomponer una política intrincada en múltiples sub-políticas simples vinculadas por dependencias de acción. [2].
- Desarrollar una arquitectura de navegación jerárquica que separe la planificación de largo horizonte de la evitación de colisiones dinámica local mediante el Actor-Critic. [4].

- Estructurar el espacio de acciones mediante grafos acíclicos dirigidos para que la distribución de la política conjunta se ajuste con mayor precisión a la distribución de valor del Critic. [2].

2.3. Objetivo general 3

Potenciar la facultad del agente para adaptarse a cambios imprevistos, como fallos de sistemas o nuevos obstáculos, sin requerir re-entrenamiento completo.

2.3.1. Objetivos específicos

- Crear un entorno de entrenamiento evolutivo que aumente progresivamente la dificultad de los mapas y la complejidad de las políticas de agentes competidores. [4].
- Integrar planificadores de puntos de ruta (waypoint planners) basados en la percepción de brechas (gaps) para permitir la navegación en escenarios con obstáculos estáticos complejos y agentes móviles. [4].
- Evaluar la resiliencia del agente Actor-Critic ante eventos estocásticos, tales como fallos aleatorios en máquinas industriales o cambios en los tiempos de procesamiento en tiempo real. [1].

2.4. Objetivo general 4

Optimizar el desempeño del agente Actor-Critic en dispositivos limitados, equilibrando la eficiencia energética, la seguridad de los datos y el éxito de la misión.

2.4.1. Objetivos específicos

- Optimizar la asignación de recursos mediante DDPG (Deep Deterministic Policy Gradient) para gestionar simultáneamente la transferencia de energía y la capacidad de transmisión. [3].
- Implementar una arquitectura Actor-Critic ligera diseñada específicamente para la computación en dispositivos IoT con baja capacidad de procesamiento. [3].
- Diseñar funciones de recompensa combinadas que integren objetivos de largo plazo (como minimizar el tiempo total de finalización) con penalizaciones por violación de restricciones de seguridad. [1, 3].

3. Metodología

3.1. Procedimiento

- ¿De qué manera la arquitectura de Bayesian Strategy Networks (BSN) mejora la eficiencia de muestreo (sample efficiency) en comparación con un Actor-Critic convencional al enfrentarse a tareas de alta dimensionalidad, como el control de un robot humanoide o un perro robótico?
- ¿Cómo logra el marco de navegación jerárquica integrar la planificación global de rutas con el aprendizaje por refuerzo local para superar la limitación de los modelos Actor-Critic estándar, que a menudo fallan al procesar obstáculos estáticos complejos como pasillos o laberintos?
- ¿Qué importancia tienen el entrenamiento paralelo y las actualizaciones asíncronas para permitir que el agente Actor-Critic mantenga su desempeño ante eventos estocásticos como averías de máquinas o cambios en los tiempos de procesamiento?

Referencias bibliográficas

- [1] C. L. Liu, C. C. Chang, and C. J. Tseng, “Actor-critic deep reinforcement learning for solving job shop scheduling problems,” *IEEE Access*, vol. 8, pp. 71 752–71 762, 4 2020.
- [2] Q. Yang and R. Parasuraman, “Bayesian strategy networks based soft actor-critic learning,” *ACM Transactions on Intelligent Systems and Technology*, vol. 15, pp. 1–24, 3 2024.
- [3] N. A. Khalek and W. Hamouda, “Improving secrecy capacity in the face of eavesdropping in swipt ciot networks with actor-critic drl,” *IEEE Open Journal of the Communications Society*, vol. 6, pp. 5328–5343, 6 2025.
- [4] K. Anand, J. Lim, R. Shiu, and M. Coskun, “Gap-guided evolutionary deep reinforcement learning for hierarchical navigation in structured dynamic environments,” in *ICDLT 2025 - Proceedings of 2025 9th International Conference on Deep Learning Technologies*. Association for Computing Machinery, Inc, 11 2025, pp. 36–43.