

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	¿Cómo mejora Actor-Critic el aprendizaje en entornos dinámicos?	1
41.	El Enfoque Actor-Critic para la Mejora de los Procesos de Aprendizaje en Entornos Dinámicos.	2
41.1.	Introducción	2
41.2.	Fundamentos Teóricos	3
41.2.1.	El Crítico: Evaluación del Valor y Error de Diferencia Temporal	3
41.2.2.	El Actor: Mejora de la Política y Regularización de Entropía	3
41.2.3.	Adaptación ante la No Estacionariedad	4
41.3.	2.3. Metodología y Análisis de la Literatura	4
41.3.1.	Enfoques en Robótica y Navegación Autónoma	4
41.3.2.	Aplicaciones en Sistemas Industriales y Gestión de Recursos	5
41.3.3.	Cuantificación de la Incertidumbre y Estructuras Bayesianas	5
41.3.4.	Análisis de Rendimiento y Convergencia	6
41.3.5.	Análisis de Estrategias Bayesianas y Descomposición de Políticas	6
41.3.6.	Casos de Estudio: De la Cirugía Robótica a la Gestión Energética	7
41.3.7.	Limitaciones e Incertidumbre en la Transferencia Sim-to-Real	7
41.3.8.	Discusión de Resultados Literarios	7
41.3.9.	Casos de Estudio en Entornos Dinámicos y Limitaciones	8
41.4.	Conclusiones	9

Parte I

¿Cómo mejora Actor-Critic el
aprendizaje en entornos dinámicos?

Capítulo 41

El Enfoque Actor-Critic para la Mejora de los Procesos de Aprendizaje en Entornos Dinámicos.

Autor: Miguel Angel Veintimilla Esparza
Técnica asignada: Actor Critic

41.1. Introducción

El despliegue de agentes inteligentes en el mundo real exige una capacidad de respuesta superior ante escenarios caracterizados por la mutabilidad y la incertidumbre. Los entornos dinámicos, que abarcan desde la navegación de vehículos de superficie no tripulados (USV) en mares estocásticos hasta la manipulación robótica en cirugías de alta precisión, se definen por la presencia de obstáculos móviles, ruidos en la percepción sensorial y dinámicas de transición que no permanecen constantes en el tiempo. [1, 2]

En este contexto, los métodos de planificación clásicos, como los campos de potencial artificial (APF) o el enfoque de ventana dinámica (DWA), presentan limitaciones significativas al depender de reglas predefinidas y mapas estáticos que no logran generalizar ante cambios imprevistos o comportamientos de agentes no cooperativos. [2–4]

El Aprendizaje por Refuerzo Profundo (DRL) ha surgido como una solución robusta al permitir que los agentes aprendan comportamientos complejos mediante la interacción directa con el entorno. [5, 6] Dentro del espectro del RL, las arquitecturas Actor-Crítico (AC) se han consolidado como un estándar debido a su capacidad para combinar las fortalezas de los métodos basados en políticas y los basados en valores. [7, 8] A diferencia de las técnicas de aprendizaje supervisado, el RL no requiere conjuntos de datos etiquetados, sino que utiliza una señal de recompensa escalar para guiar la optimización de las decisiones. No obstante, los entornos dinámicos introducen desafíos críticos como la “brecha de la realidad” (*reality gap*), donde las políticas entrenadas en simulación fallan al transferirse a plataformas físicas debido a fricciones no modeladas o variaciones en la masa y el esfuerzo de control. [3, 9, 10]

La efectividad de un agente en estos dominios depende de su habilidad para equilibrar la exploración de nuevas estrategias con la explotación del conocimiento adquirido, evitando caer en óptimos locales causados por una convergencia prematura. [7, 11] Recientes investigaciones han propuesto integrar mecanismos de entropía máxima y modelos de aprendizaje evidencial para cuantificar la incertidumbre y detectar cambios en la distribución de los datos, lo cual es vital para mantener la “plasticidad” de las redes neuronales durante largos ciclos de vida operativa. [12] A través de este análisis, se aborda formalmente la siguiente pregunta de investigación: ¿Cómo

se utilizan las arquitecturas Actor-Critic para mejorar el aprendizaje y modelar la adaptación en entornos dinámicos?

41.2. Fundamentos Teóricos

La base matemática de las arquitecturas analizadas se sustenta en el Proceso de Decisión de Markov (MDP), el cual permite formalizar la interacción entre el agente y el entorno mediante una tupla $M = (S, A, P, R, \gamma)$. [6, 8, 9] En este marco, S representa el espacio de estados, A el espacio de acciones, P la probabilidad de transición de estado, R la función de recompensa y γ el factor de descuento. [8, 13] El objetivo fundamental del agente es encontrar una política óptima π^* que maximice el retorno acumulado esperado, definido como la suma de recompensas futuras descontadas:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \quad (2.1)$$

Donde $\gamma \in [0, 1)$ determina la importancia relativa de las recompensas inmediatas frente a las de largo plazo. [5, 6, 8] La arquitectura Actor-Crítico divide al agente en dos estructuras neuronales distintas: el Actor, que parametriza la política $\pi_{\theta}(a|s)$ para seleccionar acciones, y el Crítico, que estima la función de valor para evaluar la calidad de dichas acciones. [5, 7, 14]

41.2.1. El Crítico: Evaluación del Valor y Error de Diferencia Temporal

El Crítico se encarga de aproximar la función de valor de estado $V(s)$ o la función de valor de acción $Q(s, a)$. Según la ecuación de Bellman, el valor de una acción en un estado dado es igual a la recompensa inmediata más el valor descontado del estado siguiente: [5, 6, 13]

$$Q^*(s, a) = E_{s' \sim P} \left[r(s, a) + \gamma \max_{a' \in A} Q^*(s', a') \right] \quad (2.2)$$

Para actualizar los pesos del Crítico, se utiliza el error de Diferencia Temporal (TD error), que representa la discrepancia entre la predicción actual y la recompensa observada más la estimación del valor futuro: [5, 10, 15]

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t) \quad (2.3)$$

En implementaciones avanzadas como el Soft Actor-Critic (SAC), el Crítico minimiza el error cuadrático medio de Bellman (MSBE), utilizando redes de “objetivo” (*target networks*) que se actualizan suavemente mediante promediado Polyak para estabilizar el entrenamiento: [3, 6, 16, 17]

$$L_Q(\phi) = E_{(s, a, r, s') \sim D} \left[\frac{1}{2} \left(Q_{\phi}(s, a) - \left(r + \gamma \hat{V}(s') \right) \right)^2 \right] \quad (2.4)$$

Aquí, D representa el búfer de repetición de experiencias (*experience replay*), el cual es crucial para romper la correlación temporal de las muestras y mejorar la eficiencia de los datos en entornos dinámicos. [5, 6, 17]

41.2.2. El Actor: Mejora de la Política y Regularización de Entropía

El Actor actualiza sus parámetros θ para maximizar el valor esperado proporcionado por el Crítico. En algoritmos como el Gradiente de Política Determinista Profundo (DDPG), la actualización se realiza siguiendo el gradiente de la función de valor con respecto a los parámetros de la política: [9, 17, 18]

$$\nabla_{\theta} J(\theta) \approx E_{s \sim D} \left[\nabla_a Q_{\phi}(s, a) \Big|_{a=\pi_{\theta}(s)} \nabla_{\theta} \pi_{\theta}(s) \right] \quad (2.5)$$

En escenarios dinámicos altamente inciertos, el enfoque de máxima entropía es superior. SAC modifica el objetivo de RL para incluir un término de entropía H , lo que incentiva al agente a explorar diversas acciones y evita el colapso de la política en soluciones subóptimas: [11, 17, 19, 20]

$$J(\pi) = \sum_t E_{(s_t, a_t) \sim \rho_{\pi}} [r(s_t, a_t) + \alpha H(\pi(\cdot | s_t))] \quad (2.6)$$

Donde α es un parámetro de temperatura que regula el equilibrio entre la exploración (alta entropía) y la explotación (recompensa acumulada). [3, 6, 21] El uso de críticos duales en arquitecturas como SAC y TD3 permite tomar el valor mínimo de dos estimaciones para mitigar el sesgo de sobreestimación catastrófica en las funciones de valor de acción, lo cual es una fuente común de inestabilidad en entornos dinámicos. [3, 17, 18]

41.2.3. Adaptación ante la No Estacionariedad

Una de las contribuciones teóricas más relevantes para la adaptación es el uso de críticos evidenciales y funciones de ventaja probabilísticas. En entornos no estacionales (donde las dinámicas cambian), el Crítico puede modelar la incertidumbre epistémica mediante una distribución Normal-Gamma Inversa (NIG), lo que permite al agente detectar cambios en la distribución de datos causados por la fatiga mecánica o ruidos externos. [12] El cálculo de la ventaja se convierte entonces en una variable aleatoria, permitiendo el uso de estrategias de Límite Superior de Confianza (UCB) para dirigir la exploración hacia regiones poco comprendidas del espacio de estados: [12]

$$\hat{A}_t^{UCB} = E[\hat{A}_t] + \kappa \sqrt{\text{var}[\hat{A}_t]} \quad (2.7)$$

Esta formulación garantiza que el aprendizaje no se detenga prematuramente y que el agente sea capaz de re-adaptar su política ante variaciones en la dinámica de transición sin necesidad de reentrenamiento completo. [12, 15]

41.3. 2.3. Metodología y Análisis de la Literatura

La implementación de arquitecturas Actor-Crítico (AC) en entornos dinámicos ha dado lugar a una diversidad de enfoques metodológicos que buscan mitigar la brecha entre la simulación y la realidad (sim-to-real), optimizar la eficiencia de las muestras y garantizar la seguridad operativa en condiciones de alta incertidumbre. Los autores analizados convergen en que los métodos puramente basados en datos a menudo carecen de la robustez necesaria para aplicaciones críticas, lo que ha impulsado el desarrollo de marcos híbridos que integran conocimientos previos de ingeniería y modelos de percepción avanzada.

41.3.1. Enfoques en Robótica y Navegación Autónoma

En el dominio de los vehículos de superficie no tripulados (USV) y aéreos (UAV), la metodología se ha desplazado hacia la integración de “priors” de planificación diferenciables. Un ejemplo destacado es el marco AC-DiffDWA, el cual transforma la lógica de evaluación de trayectorias del Enfoque de Ventana Dinámica (DWA) tradicional en un módulo diferenciable integrado directamente en la arquitectura Actor-Crítico. [16]

Esta metodología permite que el agente herede restricciones cinemáticas y de seguridad desde el inicio del entrenamiento, logrando una tasa de éxito del 93.6% en escenarios de encuentros

múltiples y una reducción del 88.5 % en la aceleración angular en comparación con algoritmos estándar como HR-DDPG. [16]

Por otro lado, la navegación en entornos interiores no estructurados ha sido abordada mediante el proyecto DUNE, que utiliza una combinación de CNN-LSTM para extraer características espaciotemporales de mapas de profundidad egocéntricos. [3]

Metodológicamente, DUNE introduce un filtro de ruido específico para mitigar las discrepancias sensoriales entre el simulador (IsaacGym) y el mundo físico, demostrando que la captura de información temporal es vital para evitar obstáculos dinámicos como peatones en movimiento. [3]

En una línea similar, el planificador RUMOR emplea el Espacio de Velocidad de Objetos Dinámicos (DOVS) como una capa de abstracción profunda que independiza el aprendizaje del escenario específico, permitiendo al agente generalizar comportamientos de evitación basados en el futuro predicho de los obstáculos. [4]

La integración de Modelos de Lenguaje de Gran Escala (LLM) representa una tendencia metodológica emergente. El algoritmo LLM4SAC utiliza un LLM para proporcionar orientación de alto nivel y comprensión contextual durante tareas de atraque autónomo de USV. [3]

El LLM actúa como un planificador estratégico que se consulta dinámicamente solo cuando es necesario, reduciendo el costo computacional y mejorando la adaptabilidad ante perturbaciones ambientales como el viento y las corrientes. [3]

41.3.2. Aplicaciones en Sistemas Industriales y Gestión de Recursos

En el ámbito de la gestión de infraestructuras críticas, como las plantas de tratamiento de aguas residuales, el uso de Soft Actor-Critic (SAC) ha demostrado ser superior a los controladores PID tradicionales debido a su capacidad para manejar retrasos temporales estocásticos. [19]

La metodología aquí implica el uso de un búfer de repetición de experiencias que permite al agente anticipar los efectos tardíos de las acciones de control, optimizando la eliminación de fósforo con una variabilidad significativamente menor en comparación con métodos on-policy como PPO o TRPO. [19]

En la manufactura colaborativa multi-robot (MRCMfg), se ha propuesto el algoritmo SSAC (Soft-Soft Actor-Critic), que incorpora una arquitectura de Mezcla de Expertos (MoE) y módulos Transformer. [8]

Este enfoque permite una toma de decisiones descentralizada donde cada robot ajusta su política basándose en observaciones locales, logrando una escalabilidad superior al permitir cambios en tiempo real en el número de agentes operativos sin necesidad de reentrenamiento. [8]

41.3.3. Cuantificación de la Incertidumbre y Estructuras Bayesianas

Una contribución metodológica fundamental para la adaptación en entornos no estacionales es el uso de críticos evidenciales. El enfoque EPPO (PPO Evidencial) modela la función de valor no como un escalar, sino como una distribución Normal-Gamma Inversa. [16]

Esta metodología permite cuantificar la incertidumbre epistémica, facilitando una exploración dirigida mediante el uso de límites superiores de confianza (UCB), lo que preserva la “plasticidad” de la red neuronal y evita que el agente se estanque cuando las dinámicas del entorno cambian drásticamente. [12]

Asimismo, las Redes de Estrategia Bayesianas (BSN) se utilizan para descomponer políticas complejas en sub-políticas jerárquicas vinculadas por probabilidades condicionales. [18]

El modelo BSAC permite representar dependencias cinemáticas (por ejemplo, la acción de un tobillo dependiendo de la posición de la cadera en un robot humanoide), lo que mejora drásticamente la eficiencia de la muestra y la explicabilidad del modelo en comparación con las redes de “caja negra” convencionales. [18]

A continuación, se presenta una síntesis de las dimensiones analíticas identificadas en la literatura técnica:

Tabla 41.1: Dimensiones de análisis en modelos Actor-Critic para entornos dinámicos

Parámetro	Ventaja Tecnológica	Restricción
Eficiencia de Muestra	Algoritmos off-policy como SAC reutilizan datos pasados mediante búferes de repetición, acelerando el aprendizaje en tareas complejas. [18, 19]	Alta sensibilidad a los hiperparámetros, especialmente al parámetro de temperatura α . [19, 22]
Robustez Sim-to-Real	Integración de filtros de ruido sensorial y arquitecturas CNN-LSTM para capturar contexto temporal y mitigar brechas de fidelidad. [3]	Requiere simuladores de alta fidelidad (ej. IsaacGym, EnergyPlus) que consumen recursos computacionales masivos. [3, 20]
Manejo de la Incertidumbre	Críticos evidenciales y bayesianos permiten al agente cuantificar “lo que no sabe”, evitando la convergencia a óptimos locales. [16, 18]	Complejidad matemática elevada en la formulación de las funciones de pérdida y el gradiente de la política. [12, 18]
Escalabilidad	Arquitecturas descentralizadas con Mezcla de Expertos (MoE) facilitan la coordinación de múltiples agentes en tiempo real. [8]	Conflictos potenciales en el aprendizaje de pesos cuando se integran múltiples restricciones de rendimiento (tiempo, energía, seguridad). [?]
Consumo de Cómputo	Implementaciones en hardware con memristores permiten un entrenamiento in-memory con consumos energéticos de microjulios. [15]	Limitada resolución de los dispositivos analógicos y presencia de ruido en las actualizaciones de pesos en hardware. [15]
Adaptabilidad	El uso de LLMs proporciona una capa de razonamiento semántico que ayuda a manejar casos no vistos durante el entrenamiento. [3]	Latencia en la comunicación con el modelo de lenguaje y penalizaciones en la recompensa por consultas frecuentes. [3]

41.3.4. Análisis de Rendimiento y Convergencia

El análisis comparativo revela que, si bien PPO es ampliamente utilizado por su estabilidad y simplicidad de implementación mediante el recorte del gradiente (clipping), a menudo presenta una convergencia más lenta y una menor eficiencia de datos en entornos altamente variables. [3, 19]

Por el contrario, las variantes de SAC, como UEOAC, logran una exploración más agresiva y optimista al estimar sistemáticamente la incertidumbre de los valores Q , lo que resulta especialmente beneficioso en sistemas de potencia donde la sobreestimación del valor puede llevar a soluciones de despacho subóptimas. [16, 23]

Finalmente, el uso de arquitecturas híbridas como AC-MPC combina la capacidad de re-planificación en línea del control predictivo de modelos con la flexibilidad del aprendizaje por refuerzo, permitiendo velocidades de vuelo de hasta 21 m/s en UAVs con una transferencia exitosa a plataformas físicas sin reentrenamiento adicional. [9]

41.3.5. Análisis de Estrategias Bayesianas y Descomposición de Políticas

La incorporación de Redes de Estrategia Bayesianas (BSN) representa un avance significativo en la explicabilidad del DRL. Al utilizar grafos acíclicos dirigidos para vincular variables mediante probabilidades condicionales, es posible representar el conocimiento experto y las interconexiones cinemáticas de un robot (por ejemplo, un robot cuadrúpedo o un brazo robótico). [18] En el modelo Bayesian Soft Actor-Critic (BSAC), una política conjunta $\pi(a^T|s)$ se descompone en sub-políticas π_i que siguen la regla de la cadena bayesiana: [18]

$$\pi^T(t_1, \dots, t_m) = \pi_1(t_1) \prod_{i=2}^m \pi_i(t_i | t_1, \dots, t_i) \quad (2.4)$$

Esta estructura no solo mejora la eficiencia de la muestra, sino que permite optimizar cada dimensión de la estrategia con un grado de independencia, reduciendo drásticamente el número de salidas requeridas de la red neuronal. [18] Los experimentos en entornos de OpenAI Gym han demostrado que el BSAC supera a los algoritmos de estado del arte en tareas de control continuo como Hopper y Humanoid. [18]

41.3.6. Casos de Estudio: De la Cirugía Robótica a la Gestión Energética

El modelado de la incertidumbre a través de Actor-Crítico encuentra aplicaciones críticas en diversos campos:

Cirugía Robótica: En el control de robots de continuo quirúrgicos, se utilizan redes de Actor-Crítico para aproximar términos desconocidos en las leyes de control de retroalimentación. El Crítico evalúa la relación estado-costo para penalizar errores de seguimiento y esfuerzo de control, permitiendo una precisión submilimétrica en entornos dinámicos. [1]

Gestión de Redes Eléctricas: El algoritmo UEOAC (Uncertainty Estimation Optimistic Actor-Critic) se aplica al despacho óptimo multiobjetivo en sistemas de potencia. Mediante la cuantificación sistemática de la incertidumbre en los valores Q , se mitiga la sobreestimación catastrófica y se equilibra la estabilidad de la optimización con la eficiencia de exploración en entornos con ruido observacional significativo. [23]

Logística Agrícola: Se han implementado algoritmos de búsqueda de vecindad grande adaptativa guiados por RL (RL-ALNS) para la optimización de rutas de distribución de productos agrícolas. Aquí, el Actor selecciona operadores de destrucción y reparación, mientras el Crítico evalúa la mejora en la función de costo, permitiendo adaptabilidad ante demandas dinámicas de reabastecimiento. [24]

Ciberseguridad en Redes Ópticas: El uso de SAC combinado con redes neuronales de grafos (GNN) mejoradas permite el control de acceso seguro en redes ópticas desagregadas. [16, 25] El modelo estima valores de estado-acción para detectar inyecciones de ataques estocásticos, maximizando la entropía de la política para explorar diversas configuraciones de defensa.

41.3.7. Limitaciones e Incertidumbre en la Transferencia Sim-to-Real

A pesar de los éxitos en entornos simulados, la transferencia de políticas aprendidas a robots físicos enfrenta la “brecha de realidad” (reality gap). [3,4] Esta brecha es alimentada por dinámicas no modeladas como el ruido de los sensores, la fricción variable y las perturbaciones externas (viento, corrientes marinas). [?,3] El proyecto DUNE subraya que el uso de filtros para mitigar el ruido de las cámaras de profundidad y la integración de memoria temporal a través de redes LSTM son componentes cruciales para una transferencia exitosa. Asimismo, el uso de modelos de espacio de velocidad robocéntricos, como el DOVS en el planificador RUMOR, permite abstraer la información del entorno de una manera que es independiente de la configuración específica de los obstáculos, mejorando la generalización en escenarios nunca vistos por el agente. [4]

41.3.8. Discusión de Resultados Literarios

El análisis de la literatura técnica revela una clara ventaja de las arquitecturas Actor-Crítico (AC) sobre los métodos tradicionales de Aprendizaje por Refuerzo (RL), como el Q-Learning puro o los Gradientes de Política (PG) básicos, especialmente en lo que respecta a la estabilidad y la eficiencia en espacios de acción continuos. Mientras que los métodos basados exclusivamente en el valor (como DQN) tienden a presentar oscilaciones en el control de navegación y dificultades

para converger en problemas de gran escala [9, 14, 16], las arquitecturas AC segregan el aprendizaje en dos componentes que reducen significativamente la varianza de las estimaciones [5]. El Crítico mitiga la varianza intrínseca de los gradientes de política al proporcionar una línea base (baseline) aprendida, mientras que el Actor permite una exploración más estructurada en dominios complejos. [5, 18].

Un punto de contraste fundamental entre los autores es el manejo de la sobreestimación del valor Q , un fenómeno patológico en algoritmos como DDPG donde el Actor explota los errores de aproximación del Crítico, llevando a políticas subóptimas o al colapso del aprendizaje. [13, 18] Para remediar esto, arquitecturas como TD3 y SAC introducen críticos duales, utilizando el valor mínimo de dos redes para proporcionar un límite inferior conservador. [3, 5, 8] No obstante, algunos investigadores argumentan que este enfoque puede resultar en una “infra-exploración pesimista”. En respuesta, se ha propuesto el modelo UEOAC, que estima sistemáticamente la incertidumbre del valor Q para permitir una exploración optimista basada en límites superiores de confianza (UCB), demostrando una convergencia más rápida en sistemas de potencia altamente dinámicos. [23]

En términos de estabilidad frente a eficiencia de muestra, la literatura presenta un debate entre los métodos *on-policy* y *off-policy*. Los autores que implementan PPO destacan su robustez y simplicidad gracias al mecanismo de recorte (*clipping*) del objetivo, lo que evita actualizaciones de política destructivas y garantiza una mejora monótona. [3, 8, 26] Sin embargo, se reconoce que PPO carece de la eficiencia de datos de algoritmos *off-policy* como SAC, que reutilizan experiencias pasadas mediante un búfer de repetición. [8, 19] Esta dicotomía es crucial en entornos donde la recolección de datos es costosa o peligrosa, como en la cirugía robótica o la navegación de USV en mar abierto. [1, 3]

Finalmente, la integración de conocimiento previo emerge como un factor determinante para superar las limitaciones de los modelos de “caja negra”. Investigaciones sobre AC-DiffDWA y AC-MPC demuestran que incorporar modelos cinemáticos o dinámicos analíticos dentro de la arquitectura del Actor permite a los agentes heredar restricciones de seguridad y física antes de interactuar con el entorno. [9, 16] Este enfoque híbrido no solo acelera la convergencia al evitar el aprendizaje desde cero (*tabula rasa*), sino que también mejora la generalización ante escenarios fuera de la distribución de entrenamiento (*out-of-distribution*). [9]

41.3.9. Casos de Estudio en Entornos Dinámicos y Limitaciones

La aplicabilidad de las arquitecturas Actor-Crítico se ha validado en una amplia gama de dominios críticos, proporcionando lecciones valiosas sobre su implementación real:

Navegación Ágil y Carreras de Drones: El marco AC-MPC ha demostrado un rendimiento “sobrehumano” en carreras de cuadricópteros, alcanzando velocidades de hasta 21 m/s . [9] El estudio revela que, aunque el entrenamiento es computacionalmente intensivo (hasta 30 veces más lento que PPO estándar debido a la optimización por lotes), la capacidad de replanificación en línea del MPC integrado permite una transferencia *sim-to-real* exitosa sin reentrenamiento. [9] No obstante, una limitación crítica identificada es la incapacidad actual de estos *solvers* para manejar restricciones de estado directas, limitándose a límites de entrada (voltajes/torques).

Cirugía Robótica de Alta Precisión: En el control de robots de continuo, el uso de leyes de aprendizaje basadas en Lyapunov dentro de un esquema AC garantiza que el sistema permanezca dentro de “tubos de seguridad” monótonos. [?, 1] Los experimentos muestran una convergencia 3.5 veces más rápida que los métodos adaptativos tradicionales, reduciendo drásticamente el esfuerzo de control inicial, lo cual es vital para evitar daños en tejidos biológicos durante procedimientos mínimamente invasivos. [1]

Gestión de Redes Eléctricas y Agua: En plantas de tratamiento de aguas residuales, SAC ha demostrado ser superior para manejar retrasos temporales estocásticos en la retroalimentación de sensores químicos. [19] Mientras que PPO y TRPO presentan una alta variabilidad en estos

escenarios, SAC mantiene una desviación estándar significativamente menor (3.75 frente a > 26), lo que se traduce en una operación más estable y económica. [19]

Hardware de Bajo Consumo y Memristores: Un caso de estudio innovador es la implementación de redes AC en memristores analógicos, imitando el aprendizaje basado en recompensas biológicas. [15] Este enfoque permite realizar el cálculo de gradientes e incrementos de peso directamente en la memoria (*in-memory computing*), consumiendo apenas $28,2 \mu J$ por actualización. [15] Sin embargo, la principal limitación reside en el ruido de los dispositivos analógicos y la resolución limitada de los pesos, lo que ralentiza la convergencia en comparación con las simulaciones de software ideales. [15]

Limitaciones y Desafíos Transversales

A pesar de los éxitos, persisten desafíos fundamentales. La sensibilidad a los hiperparámetros sigue siendo el “talón de Aquiles” de muchas arquitecturas AC. Algoritmos como SAC dependen críticamente del parámetro de temperatura α para balancear la exploración, y una sintonización incorrecta puede llevar a una convergencia prematura o a una política puramente aleatoria. [19, 20, 26] En entornos no estacionales (donde las dinámicas cambian con el tiempo, como el desgaste de una articulación robótica), se observa una pérdida de plasticidad en la red del Crítico, lo que impide que el agente siga aprendiendo después de los primeros ciclos de entrenamiento. [12]

Otra limitación notable es la complejidad computacional y escalabilidad. El uso de arquitecturas profundas con millones de parámetros, aunque potente para la extracción de características, dificulta el despliegue en sistemas integrados con recursos limitados. [8, 15] Además, la mayoría de los modelos aún enfrentan la “brecha de realidad” (*reality gap*), donde ruidos no modelados en sensores o variaciones en la fricción ambiental degradan el rendimiento de políticas entrenadas exclusivamente en simuladores. [3] Finalmente, el manejo de restricciones de seguridad estrictas en RL sigue siendo un campo abierto, ya que penalizar las violaciones en la función de recompensa no garantiza que estas no ocurran durante la fase de exploración activa. [9, 23]

41.4. Conclusiones

El análisis exhaustivo de este capítulo permite concluir que las arquitecturas de Actor-Crítico proporcionan una base explicable y robusta para resolver la incertidumbre en sistemas autónomos dinámicos. La transición de modelos puramente basados en datos hacia enfoques híbridos —que incorporan priors de planificación diferenciable, descomposiciones bayesianas y cuantificación de incertidumbre evidencial— representa el camino más viable hacia la Inteligencia General Artificial en robótica.

La respuesta a la pregunta de investigación central reside en la capacidad de estas arquitecturas para tratar la incertidumbre no como un obstáculo, sino como una señal informativa. Mientras que el SAC utiliza la entropía para garantizar una exploración estructurada, el aprendizaje evidencial y los modelos bayesianos permiten al agente “saber lo que no sabe”, ajustando su política de manera conservadora ante situaciones de alta varianza o cambios en la dinámica del entorno. Esta sinergia entre el rigor matemático del MDP y la flexibilidad de las redes neuronales profundas establece el estándar para la próxima generación de sistemas de navegación y control autónomo.

El análisis técnico desarrollado a lo largo de este capítulo permite concluir que las arquitecturas Actor-Crítico (AC) representan un paradigma de control superior para la gestión de la incertidumbre y la adaptación en sistemas autónomos dinámicos. La principal fortaleza de este marco reside en la segregación funcional entre la estructura de política (Actor) y la estructura de evaluación (Crítico), lo cual mitiga de manera efectiva la varianza de los gradientes que tradicionalmente ha obstaculizado la convergencia de los métodos de búsqueda directa de política. Esta separación permite que el Crítico aproxime la función de valor mediante el error de diferencia

temporal (TD error), proporcionando una línea base aprendida que guía las actualizaciones del Actor de forma más estable que los métodos de aprendizaje puramente basados en el valor, los cuales tienden a presentar oscilaciones catastróficas en espacios de acción continuos .

Desde una perspectiva de rendimiento técnico, los hallazgos demuestran que la arquitectura AC es la base algorítmica más robusta para enfrentar la alta dimensionalidad. Algoritmos representativos como el Soft Actor-Critic (SAC) han demostrado ser fundamentales al incorporar la regularización de la entropía máxima, lo que incentiva una exploración estructural del espacio de estados y previene el colapso de la política en óptimos locales, un problema recurrente en los métodos deterministas clásicos . Asimismo, la capacidad de estas redes para integrar componentes de extracción de características complejas —como las capas CNN-LSTM— facilita la captura de dependencias espaciotemporales, permitiendo a los agentes inteligentes navegar en entornos no estructurados con una comprensión profunda del contexto dinámico .

Uno de los hallazgos técnicos más significativos es la respuesta de estas arquitecturas ante la no estacionalidad. La literatura analizada subraya que, mediante el uso de críticos evidenciales (como en el modelo EPPO), es posible cuantificar la incertidumbre epistémica y preservar la plasticidad de la red neuronal . Este mecanismo permite que el sistema detecte cambios en la distribución de los datos causados por variaciones en la dinámica ambiental —tales como fricciones variables o perturbaciones externas— ajustando la política de manera proactiva sin requerir un reentrenamiento completo . Además, el empleo de búferes de repetición de experiencia en marcos *off-policy* garantiza una eficiencia de muestra que resulta vital en aplicaciones donde el coste computacional o el riesgo físico de la interacción es elevado .

Finalmente, este capítulo concluye que la evolución del Actor-Crítico hacia modelos híbridos y diferenciables representa el estado del arte en ingeniería de control. La integración de *priors* estructurados, tales como el Control Predictivo de Modelo (MPC) o el Enfoque de Ventana Dinámica (DWA) en formatos diferenciables dentro de la arquitectura AC, permite a los agentes heredar restricciones cinemáticas y de seguridad desde el inicio del proceso de aprendizaje . Esta sinergia no solo acelera la convergencia algorítmica, sino que garantiza que las acciones del sistema respeten los límites físicos del hardware, cerrando eficazmente la brecha entre la simulación y la realidad (*sim-to-real*) . En suma, la arquitectura Actor-Crítico provee un marco explicable, escalable y matemáticamente riguroso para la próxima generación de sistemas de decisión autónoma en entornos de alta complejidad.

Referencias

- [1] M. Jabari, A. Botta, L. Tagliavini, C. Visconte, and G. Quaglia, “A safe, high-precision reinforcement learning-based optimal control of surgical continuum robots: A monotone tube boundary approach with prescribed-time control capability,” *Robotics and Autonomous Systems*, vol. 190, 8 2025, dOI: 10.1016/j.robot.2025.104992.
- [2] Z. Zhang, Z. Li, Y. Wang, J. Miao, and X. Xie, “Aeoas: Sac with conservative q-learning for usv obstacle avoidance in unknown marine environments,” in *IFAC-PapersOnLine*, vol. 59. Elsevier B.V., 8 2025, pp. 651–656, dOI:10.1016/j.ifacol.2025.11.708.
- [3] C. Xu, Y. Chu, Q. Gao, Z. Wu, J. Wang, Y. Yue, W. Dominik, and X. Zhu, “Autonomous unmanned surface vehicle docking using large language model guide reinforcement learning,” *Ocean Engineering*, vol. 323, 4 2025, dOI: 10.1016/j.oceaneng.2025.120608.
- [4] D. Martinez-Baselga, L. Riazuelo, and L. Montano, “Rumor: Reinforcement learning for understanding a model of the real world for navigation in dynamic environments,” *Robotics and Autonomous Systems*, vol. 191, 9 2025, dOI: 10.1016/j.robot.2025.105020.
- [5] O. Dogru, K. Velswamy, and B. Huang, “Actor–critic reinforcement learning and application in developing computer-vision-based interface tracking,” *Engineering*, vol. 7, pp. 1248–1261, 9 2021, dOI: 10.1016/j.eng.2021.04.027.
- [6] B. Tao and J. H. Kim, “Deep reinforcement learning-based local path planning in dynamic environments for mobile robot,” *Journal of King Saud University - Computer and Information Sciences*, vol. 36, 12 2024, dOI: 10.1016/j.jksuci.2024.102254.
- [7] P. Kumar, L. Hota, B. P. Nayak, and A. Kumar, “An adaptive contention window using actor-critic reinforcement learning algorithm for vehicular ad-hoc networks,” in *Procedia Computer Science*, vol. 235. Elsevier B.V., 2024, pp. 3045–3054, dOI: 10.1016/j.procs.2024.04.288.
- [8] Q. Yang, W. Fan, N. Ma, S. Lin, J. Chang, Z. Zou, L. Sun, and H. Zhang, “Bilevel scheduling in downstream oil supply chain: Integrating reinforcement learning with mathematical programming,” *Computers and Chemical Engineering*, vol. 204, 1 2026, dOI: 10.1016/j.compchemeng.2025.109381.
- [9] A. Romero, E. Aljalbout, Y. Song, and D. Scaramuzza, “Actor-critic model predictive control: Differentiable optimization meets reinforcement learning for agile flight,” *IEEE Transactions on Robotics*, vol. 42, pp. 673–692, 12 2025, dOI: 10.1109/TRO.2025.3644945. [Online]. Available: <http://arxiv.org/abs/2306.09852><http://dx.doi.org/10.1109/TRO.2025.3644945>
- [10] S. N. Omkar, K. Maski, and S. Saju, “Adaptive pid tuning for quadcopters in dynamic environments using advantage actor-critic reinforcement learning,” in *2025 IEEE International Conference on Emerging Technologies in Autonomous Aerial Vehicles, ETAAV 2025 - Proceedings*. Institute of Electrical and Electronics Engineers Inc., 2025, dOI: 10.1109/ETAAV66793.2025.11213110.

- [11] G. Sharma and S. Jain, “Deep reinforcement learning-based framework for path planning of auavs,” in *Procedia Computer Science*, vol. 258. Elsevier B.V., 2025, pp. 1112–1122, doi: 10.1016/j.procs.2025.04.346.
- [12] A. Akgül, G. Baykal, M. Haußmann, and M. Kandemir, “Overcoming non-stationary dynamics with evidential proximal policy optimization,” *Transactions on Machine Learning Research (TMLR)*, vol. 2025-November, 11 2025. [Online]. Available: <http://arxiv.org/abs/2503.01468>
- [13] L. Zheng, Y. H. Wang, R. Yang, S. Wu, R. Guo, and E. Dong, “An efficiently convergent deep reinforcement learning-based trajectory planning method for manipulators in dynamic environments,” *Journal of Intelligent and Robotic Systems: Theory and Applications*, vol. 107, 4 2023, doi: 10.1007/s10846-023-01822-5.
- [14] C. L. Liu, C. C. Chang, and C. J. Tseng, “Actor-critic deep reinforcement learning for solving job shop scheduling problems,” *IEEE Access*, vol. 8, pp. 71 752–71 762, 4 2020, doi: 10.1109/ACCESS.2020.2987820.
- [15] K. Portner, T. Zellweger, F. Martinelli, L. Bégon-Lours, V. Bragaglia, C. Weilenmann, D. Jubin, D. F. Falcone, F. Hermann, O. Hrynkevych, T. Stecconi, A. L. Porta, U. Drechsler, A. Olziersky, B. J. Offrein, W. Gerstner, M. Luisier, and A. Emboras, “Actor–critic networks with analogue memristors mimicking reward-based learning,” *Nature Machine Intelligence*, vol. 7, pp. 1939–1953, 12 2025, doi: 10.1038/s42256-025-01149-w.
- [16] H. Hu, S. Qu, and Z. Xu, “Ac-diffdwa: Unmanned surface vehicle path planning using actor–critic with differentiable dynamic window approach,” *Advanced Engineering Informatics*, vol. 74, 9 2026, doi: 10.1016/j.aei.2026.104732.
- [17] T. Bank, F. W. Madsen, H. Mirshekali, and H. R. Shaker, “Reinforcement-learning-driven prescriptive operation and maintenance of distributed energy storage for cost-effective grid asset protection,” *Journal of Energy Storage*, vol. 141, 1 2026, doi: 10.1016/j.est.2025.119338.
- [18] Q. Yang and R. Parasuraman, “Bayesian soft actor-critic: A directed acyclic strategy graph based deep reinforcement learning,” in *Proceedings of the ACM Symposium on Applied Computing*. Association for Computing Machinery, 4 2024, pp. 646–648, doi: 10.1145/3605098.3636113.
- [19] E. Mohammadi, D. Ortiz-Arroyo, A. A. Hansen, M. Stokholm-Bjerregaard, S. Gros, A. S. Anand, and P. Durdevic, “Application of soft actor-critic algorithms in optimizing wastewater treatment with time delays integration,” *Expert Systems with Applications*, vol. 277, 6 2025, doi: 10.1016/j.eswa.2025.127180.
- [20] A. Kathirgamanathan, E. Mangina, and D. P. Finn, “Development of a soft actor critic deep reinforcement learning approach for harnessing energy flexibility in a large office building,” *Energy and AI*, vol. 5, 9 2021, doi: 10.1016/j.egyai.2021.100101.
- [21] J. Shi, S. Zhou, F. Guo, and C. Li, “Multi-task learning-based adaptive soft actor-critic for real-time uav trajectory planning,” *Institute of Electrical and Electronics Engineers (IEEE)*, 11 2025, pp. 1216–1222, doi: 10.1109/ispas67752.2025.00167.
- [22] J. Cen, L. Zeng, X. Liu, X. Li, Y. Li, J. Yang, C. Huang, and F. Deng, “Intrinsic reward-driven sac-ircnet: A novel energy-saving control method for hvac systems,” *IEEE Transactions on Automation Science and Engineering*, 2026, doi: 10.1109/TASE.2026.3679538.

- [23] J. Shang, Z. Kang, R. Zhu, and X. Zhu, “Multi-objective optimal dispatch in power systems via q-value uncertainty estimation-based optimistic actor-critic,” *Electric Power Systems Research*, vol. 251, 2 2026, doi: 10.1016/j.epsr.2025.112264.
- [24] D. Zhu, Q. Liu, D. Zuo, L. Yin, B. Li, J. Hu, C. Yan, B. He, and C. Xue, “A reinforcement learning model for dynamic distribution route optimization of agricultural products under replenishment demand,” *Alexandria Engineering Journal*, vol. 132, pp. 156–168, 11 2025, doi: 10.1016/j.aej.2025.09.073.
- [25] Z. Zhao and Y. Wang, “Soft actor-critic algorithm and improved gnn model in secure access control of disaggregated optical networks,” *Scientific Reports*, vol. 15, 12 2025, doi: 10.1038/s41598-025-15225-z.
- [26] A. M. Farid, J. Roshanian, and M. Mouhoub, “On-policy actor-critic reinforcement learning for multiple unmanned aerial vehicle exploration,” *Expert Systems with Applications*, 6 2026, doi: 10.1016/j.eswa.2026.131496.